

به نام خدا



دانشگاه صنعتی شریف  
دانشکده مهندسی کامپیوتر

هوش مصنوعی

تمرین ۵: Neural Networks

مهراد میلانلو

۹۹۱۰۵۷۷۵

## سوال ۱

فرض کنید که هیچ تابع Activation غیرخطی نداشته باشیم. و همگی خطی باشند. آنگاه نشان می‌دهیم خروجی شبکه‌ی عصبی چندلایه، صرفاً یک تابع خطی از ورودی‌ها خواهد بود.

$$f_i(X) = W_i^T X + B_i$$


$$\Rightarrow y = f_n(f_{n-1}(f_{n-2}(\dots) + B_{n-2}) + B_{n-1}) = \left( \prod_{i=1}^n W_i \right) X + \sum_{i=1}^n \left( \prod_{j=i+1}^n W_j \right) B_i$$

$$\Rightarrow y = WX + B$$

بنابراین خروجی این شبکه‌ی عصبی چندلایه یک تبدیل خطی است و تنها می‌تواند مدل‌هایی که رفتار خطی دارند را یاد بگیرد. در صورتی که هدف استفاده از شبکه‌ی عصبی شامل لایه‌ی های مخفی آن است که بتوانیم داده‌ها با اشکال مختلف را یاد بگیریم و عملاً با این کار استفاده از شبکه‌ی عصبی چند لایه بی‌تاثیر می‌شود.

## سوال ۲

برای تشخیص نقاط سبز از نقاط نارنجی کافی‌ست نامعادله‌ی  $|x_1| + |x_2| \leq 1$  را حل کنیم. برای حل این نامعادله نیز با استفاده از شبکه‌ی عصبی، آن را ابتدا به چهار بخش تقسیم می‌کنیم.



در واقع نامعادله را به چهار قسمت زیر تقسیم می‌کنیم:

$$\begin{cases} x_1 - x_2 \leq 1 \\ -x_1 + x_2 \leq 1 \\ -x_1 - x_2 \leq 1 \\ x_1 + x_2 \leq 1 \end{cases}$$


و در نهایت اگر ورودی در تمام این نامعادلات صدق کند، خروجی شبکه ۱ و در غیر این صورت ۰ خواهد بود. ورودی‌های شبکه به ترتیب  $x_1, x_2$  هستند.

همین‌طور در لایه‌ی اول تابع فعال‌سازی تابع Sign است.  $Sign(x) = \begin{cases} 1 & \text{if } x \geq 0 \\ -1 & \text{if } x < 0 \end{cases}$ . در لایه‌ی آخر نیز تابع فعال‌سازی تابع

Step است.  $Step(x) = \begin{cases} 1 & \text{if } x \geq 0 \\ 0 & \text{if } x < 0 \end{cases}$ . بایاس لایه‌ی آخر نیز طوری قرار دادیم که اگر هر ۴ خروجی لایه‌ی قبلی ۱ بود، خروجی ۱ بدهد.

## سوال ۳

شبکه‌ی عصبی را به‌گونه‌ی زیر طراحی می‌کنیم:



مقدار روشنایی هر پیکسل را به‌عنوان ورودی‌های شبکه‌ی عصبی از  $x_1$  تا  $x_6$  در نظر می‌گیریم. سپس با استفاده از ضریب یکسان  $0.25$ ، میانگین روشنایی پیکسل‌های هر ناحیه را محاسبه کرده و به لایه‌ی بعدی شبکه می‌رویم. اکنون می‌خواهیم بین میانگین‌های محاسبه شده که هرکدام مربوط به یک ناحیه هستند، مقدار ماکسیمم را مشخص کنیم تا خروجی شبکه باشد. در این لایه، تابع فعال‌سازی را تابع Sign در نظر

می‌گیریم:  $Sign(x) = \begin{cases} 1 & \text{if } x \geq 0 \\ -1 & \text{if } x < 0 \end{cases}$ . ضریب‌ها را طوری تعیین می‌کنیم که به‌ترتیب از بالا به پایین، مقدار ورودی به تابع فعال‌سازی،

مقدار میانگین روشنایی ناحیه‌ی  $i$ ام باشد. در لایه‌ی بعدی، باید مشخص کنیم کدام  $z_i$  از بقیه بیش‌تر است و در واقع حاصل تفاضل بقیه‌ی  $z_j$ ها از آن مثبت می‌شود. که این را نیز با مشخص کردن ضرایب مناسب و تابع فعال‌سازی Sign انجام می‌دهیم. دقت کنید که مقدار بایاس  $b = -2/9$  مشخص می‌کنیم که  $z_i$  باید لزوماً از روشنایی هر سه ناحیه‌ی دیگر بیش‌تر باشد. در لایه‌ی نهایی نیز به خروجی روشنایی هر ناحیه، ضریب شماره‌ی همان ناحیه را می‌دهیم. تابع فعال‌سازی این لایه را

نیز تابع Step در نظر می‌گیریم.  $Step(x) = \begin{cases} 1 & \text{if } x \geq 0 \\ 0 & \text{if } x < 0 \end{cases}$ . چون فقط خروجی یک ناحیه ۱ و بقیه ۰ هستند، مقدار آن در ضریب مربوطه

ضرب شده و خروجی نهایی این شبکه‌ی عصبی، شماره‌ی ناحیه‌ای است که میانگین روشنایی پیکسل‌های آن ماکسیمم است.

## سوال ۴

فرض کنید ورودی‌های شبکه  $X_1, X_2, X_3$  باشند. در لایه‌ی میانی شبکه، هر نورون دو ورودی دارد و تابع فعالسازی آن  $f(X) = \lfloor \frac{X}{4} \rfloor$  است. بنابراین با توجه به ورودی‌های این نورون، خروجی آن این چنین است:

$$f(X) = \lfloor \frac{X}{4} \rfloor = \begin{cases} 0 & \text{if } X_1 + X_2 = 0 \\ 1 & \text{if } X_1 + X_2 = 1 \\ 2 & \text{if } X_1 + X_2 = 2 \end{cases}$$


بنابراین واضح است که عملکرد این تابع مشابه تابع  $AND$  است. به‌طریق مشابه برای تابع فعالساز لایه‌ی خروجی داریم:

$$g(Y) = \lceil \frac{Y}{3} \rceil = \begin{cases} 0 & \text{if } Y_1 + Y_2 + Y_3 = 0 \\ 1 & \text{if } Y_1 + Y_2 + Y_3 = 1 \\ 1 & \text{if } Y_1 + Y_2 + Y_3 = 2 \\ 1 & \text{if } Y_1 + Y_2 + Y_3 = 3 \end{cases}$$

که عملکرد این تابع مشابه تابع  $OR$  با سه ورودی است. بنابراین واضح است که خروجی این شبکه‌ی عصبی برحسب ورودی‌ها برابر است با:

$$O(X_1, X_2, X_3) = (X_1 \wedge X_2) \vee (X_1 \wedge X_3) \vee (X_2 \wedge X_3)$$

که این رابطه بیانگر آن است که اگر دو ورودی مقدار ۱ داشته باشند، مقدار خروجی ۱ و در غیر این صورت مقدار خروجی ۰ می‌شود. پس می‌توان این شبکه‌ی عصبی را به شکل ساده‌تر زیر پیاده‌سازی کرد.



که تابع فعالسازی  $Z(X) = \lfloor \frac{X}{4} \rfloor$  است. واضح است که این شبکه‌ی عصبی خروجی مشابه دارد.

## سوال ۵

توابع شبکه‌ی عصبی سوال را، از چپ به راست  $f, g, o$  می‌نامیم. بنابراین خواهیم داشت:

$$f = w_1x + w_2y$$

$$g = w_4f \times w_3z = w_3w_4zf$$

$$o = \sigma(w_6 + w_5g)$$

اکنون با توجه به مقادیر داده شده و اینکه تمام وزن ها برابر  $\frac{1}{4}$  هستند، عملیات feed forward را انجام می دهیم:

$$f = w_1x + w_2y = \frac{1}{4} \times 1 + \frac{1}{4} \times 3 = 1$$

$$g = w_3f \times w_4z = w_3w_4zf = \frac{1}{4} \times \frac{1}{4} \times 7 \times 2 = 0.875$$

$$o = \sigma(w_5 + w_6g) = \sigma\left(\frac{1}{4} + \frac{1}{4} \times 0.875\right) \approx 0.905$$

حال به سراغ عملیات backpropagation می رویم. در حالت عادی، باید تابع cost function در اختیارمان قرار داده می شد تا با محاسبه مشتق جزئی آن نسبت به ضرایب  $w$  یعنی  $\frac{\partial C}{\partial w}$  بتوانیم تاثیر تغییر هر یک را روی کم یا زیاد شدن cost function بسنجیم. اما در این سوال، مشتق خروجی شبکه یعنی  $o$  را نسبت به ضرایب  $w$  محاسبه می کنیم. بنابراین خواهیم داشت:

$$\begin{aligned} \sigma(x) = \frac{1}{1 + e^{-x}} &\Rightarrow \frac{d\sigma(x)}{dx} = \frac{e^{-x}}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} \left(1 - \frac{1}{1 + e^{-x}}\right) \\ &\Rightarrow \frac{d\sigma(x)}{dx} = \sigma(x)(1 - \sigma(x)) \end{aligned} \quad (1)$$

$$\stackrel{(1)}{\rightarrow} \frac{\partial o}{\partial w_5} = o(1 - o) = 0.905(1 - 0.905) \Rightarrow \boxed{\frac{\partial o}{\partial w_5} = 0.086}$$

$$\stackrel{(1)}{\rightarrow} \frac{\partial o}{\partial w_6} = g(o(1 - o)) = 0.875(0.905(1 - 0.905)) \Rightarrow \boxed{\frac{\partial o}{\partial w_6} = 0.074}$$

برای محاسبه ی باقی مشتقات جزئی، نیاز است یک لایه به عقب تر برگردیم:

$$\frac{\partial o}{\partial w_3} = \frac{\partial o}{\partial g} \frac{\partial g}{\partial w_3} \stackrel{(1)}{\rightarrow} \frac{\partial o}{\partial w_3} = w_6(o(1 - o)) \times w_4zf = \frac{1}{4} \times 0.086 \times \frac{1}{4} \times 7 \times 2 \Rightarrow \boxed{\frac{\partial o}{\partial w_3} = 0.074}$$

$$\frac{\partial o}{\partial w_4} = \frac{\partial o}{\partial g} \frac{\partial g}{\partial w_4} \stackrel{(1)}{\rightarrow} \frac{\partial o}{\partial w_4} = w_6(o(1 - o)) \times w_3zf = \frac{1}{4} \times 0.086 \times \frac{1}{4} \times 7 \times 2 \Rightarrow \boxed{\frac{\partial o}{\partial w_4} = 0.074}$$

مجدداً برای محاسبه باقی مشتقات جزئی، نیاز است یک لایه به عقب تر برگردیم:

$$\frac{\partial o}{\partial w_2} = \frac{\partial o}{\partial g} \frac{\partial g}{\partial f} \frac{\partial f}{\partial w_2} \stackrel{(1)}{\rightarrow} \frac{\partial o}{\partial w_2} = w_6(o(1 - o)) \times w_3w_4zy = \frac{1}{4} \times 0.086 \times \frac{1}{4} \times \frac{1}{4} \times 7 \times 3 \Rightarrow \boxed{\frac{\partial o}{\partial w_2} = 0.022}$$

$$\frac{\partial o}{\partial w_1} = \frac{\partial o}{\partial g} \frac{\partial g}{\partial f} \frac{\partial f}{\partial w_1} \stackrel{(1)}{\rightarrow} \frac{\partial o}{\partial w_1} = w_6(o(1 - o)) \times w_3w_4zx = \frac{1}{4} \times 0.086 \times \frac{1}{4} \times \frac{1}{4} \times 7 \times 1 \Rightarrow \boxed{\frac{\partial o}{\partial w_1} = 0.007}$$

اکنون این عملیات نیز به پایان می رسد و با توجه به مقدار هدف خروجی و  $\eta$  یعنی learning rate، وزن یال های شبکه را با استفاده از gradient descent می توان آپدیت کرد.